

第八届中国研究生人工智能创新大赛

【面向低算力平台的实时跌倒检测】

项目文档

2026. 09. 01

抹茶吃不饱

企业赛题七

目录

1 项目概况..... 1

1.1 研究背景与问题定义..... 1

1.2 研究目标与应用价值..... 2

1.3 数据、知识与软硬件来源..... 2

2 项目规划与创新性论证..... 3

2.1 总体目标与评价协议..... 3

2.2 相关路线比较..... 3

2.3 创新点与技术贡献..... 4

3 实施方案..... 5

3.1 总体架构..... 5

3.2 姿态轨迹与候选事件..... 5

3.3 双尺度时序与七头融合..... 7

3.4 训练、验证与模型选择..... 7

3.5 推理结果与运行证据..... 9

3.6 工程化与风险控制..... 10

4 结论与潜在应用..... 10

5 参考资料..... 11

5.1 数据集与核心方法来源..... 11

5.2 时序建模、骨架动作与视觉表征论文..... 11

5.3 融合、评价协议与部署研究论文..... 12

记录更改历史

表 1 文档与模型开发更改历史

序号	更改原因	版本	作者	日期	备注
1	建立 rule-only 物理规则与批量评测基线	V0.1	抹茶吃不饱	2026.08.17	OF-Syn val: mAP* 43.827%
2	训练 16 帧 FallTCN 并完成严格端点融合消融	V0.2	抹茶吃不饱	2026.08.17	TCN 49.987%; 固定融合 51.562%
3	引入行为均衡、hard-negative 与 clip-level MIL	V0.3	抹茶吃不饱	2026.08.18	代表种子 57.483%; 三种子过门
4	加入 FallVision 外部预训练、蒸馏与异构时序专家	V0.4	抹茶吃不饱	2026.08.22	研究 val 单模型最高 70.229%
5	加入 320 Person-ROI F1, 转入五折 grouped OOF	V0.5	抹茶吃不饱	2026.08.28	67.650 / 73.717 / 61.584%
6	融合 320/640 双分辨率并扩展独立 ROI 头	V0.6	抹茶吃不饱	2026.08.29	双头 69.205%; 六头 70.831%
7	加入原生 dense-48 长时专家, 冻结七头 equal-logit	V1.0	抹茶吃不饱	2026.08.29	OOF: 72.166 / 78.762 / 65.570%
8	完成无标签候选提议、全量训练和锁定开发验证	V1.1	抹茶吃不饱	2026.09.01	75.208 / 77.907 / 72.509%; 非测试
9	冻结运行包、参数与复现证据, 补全文献和视频	V1.2	抹茶吃不饱	2026.09.01	4.053M; 15.46 MiB; 538 passed
10	补充 NVIDIA V100 完整视频端到端实测	V1.3	抹茶吃不饱	2026.09.01	58.483 s; 14.77 ms/frame; score 0.749772
11	重构模型演进、实验边界、失败路线与部署结论	V1.4	抹茶吃不饱	2026.09.01	统一 OOF、开发验证与 V100 口径
12	补齐全部表格表题、编号与跨页重复表头	V1.5	抹茶吃不饱	2026.09.01	10 个表格统一编号并保留列标题

1 项目概况

1.1 研究背景与问题定义

跌倒检测的核心难点并非识别某一静态姿态，而是从连续视频中区分正常坐卧、弯腰、快速下蹲与真实失衡过程。单帧分类容易忽略速度、持续时间和落地后的状态变化；完全依赖 RGB 的大规模视频模型虽然表达能力强，但对算力、数据规模和部署环境提出更高要求。本项目因此将问题定义为：在普通 RGB 视频上，以人体轨迹为分析单位，对短时姿态变化、长时动作上下文和人体区域视觉信息进行联合建模，输出片段级跌倒风险及可复核的候选时间区间。

系统坚持无标签推理约束：部署阶段只读取视频像素、帧率和运行时生成的人体框、关键点与轨迹，不读取类别标签、真实事件区间或真实人物 ID。该约束使离线验证、现场演示与最终运行包采用同一信息边界，降低因评测数据特定信息进入推理流程造成的偏差。

1.2 研究目标与应用价值

表 2 项目研究问题、设计目标与可验证输出

研究问题	设计目标	可验证输出
如何兼顾精度与低算力部署？	复用单一姿态视觉主干，用轻量时序编码和多头融合补充表达能力。	4.053M 参数、15.46 MiB FP32 参数量
如何降低单一时间尺度的遗漏？	同时编码 16 帧局部动态和 48 帧连续上下文。	六个短时头 + 一个长时专家
如何使告警可解释？	保留轨迹、候选区间、成员 logits 与融合规则。	结构化 JSON 和逐帧可视化
如何保证交付可复现？	冻结权重、依赖、协议和逐文件 SHA-256。	MANIFEST.json 与烟测记录

潜在应用包括养老机构、家庭看护、病房与康复区域的风险辅助发现。系统定位为值守人员的辅助工具：告警用于触发人工回看和后续处置，不作为医疗诊断或唯一决策依据。

1.3 数据、行业知识、算法与硬件来源

表 3 数据、算法、知识与软硬件来源

类别	来源	用途	边界与引用
训练/验证数据	OmniFall 标注、OF-Syn 合成视频	时序模型训练与验证	沿用项目记录的数据划分; Schneider et al., 2025
工程演示数据	UR Fall Detection Dataset	公开视频端到端演示	fall-01 / fall-02 / fall-10; Kępski, n.d.
姿态算法	YOLO11 Pose	17 点姿态、人体框	方法参考见 Khanam & Hussain, 2024; 运行版本见冻结包
深度学习框架	PyTorch	模型加载与推理	版本与依赖由冻结运行包记录
行业知识	跌倒过程的运动学与持续性	候选区间及解释设计	不包含身份识别或医疗诊断
运行硬件	NVIDIA V100 / CUDA GPU / CPU 烟测环境	模型推理与工程核验	V100 与本机、CPU 结果分开报告

数据与第三方组件仅在各自许可和引用边界内使用。本项目提交包不重新分发原始数据集；最终运行包通过哈希清单记录源码、权重和依赖文件，便于复核来源与版本一致性。

2 项目规划与创新性论证

2.1 总体目标与评价协议

项目以排序质量、工程效率和可审计性为三类目标。文中 mAP^* 定义为 $(P@R90+P@R95)/2$ ，是两个高召回工作点精确率的算术平均，并非标准 Average Precision。早期 OF-Syn validation 用于建立可运行基线；后期模型结构以 9,600 个 train clips 的 template-grouped 五折 OOF 为主要选择证据；结构冻结后只执行一次 1,200-clip 无标签开发验证。这三类证据在表格中分别标注，封存测试和外部确认数据均不得参与后续调参。

表 4 冻结七头模型关键指标与证据口径

指标层级	指标	冻结结果	解释
结构选型	mAP^* / $P@R90$ / $P@R95$	72.166% / 78.762% / 65.570%	9,600 train clips; 五折 template-grouped OOF; 用于模型比较
部署资格	mAP^* / $P@R90$ / $P@R95$	75.208% / 77.907% / 72.509%	1,200 OF-Syn val; 唯一一次锁定无标签开发验证; 非封存测试
模型规模	参数 / FP32	4.053M / 15.46 MiB	共享视觉、短/长时序模块与七个输出头
运行效率	V100 平均时延	14.77 ms/frame (约 67.7 FPS)	PyTorch 2.9.0 + CUDA 12.8; 3,960 帧端到端均值, 非 P95
完整视频输出	模型分数 / 候选区间	0.749772 / 45.57 - 49.57 s	V100; 候选峰值 47.57 s; 视频 30 FPS; 分数不是准确率

2.2 相关技术路线比较

表 5 跌倒检测相关技术路线比较

技术路线	信息来源	主要优势	主要局限	本项目关系
可穿戴传感器	加速度/陀螺仪	不依赖光照	依从性和维护成本	目标是无穿戴视觉辅助
RGB-D / 深度相机	彩色+深度	几何信息直接	专用硬件和布设约束	采用普通 RGB 降低门槛
单帧姿态分类	单帧关键点	计算链路短	缺少动作时序	引入 16/48 帧因果编码
大型 RGB 视频模型	完整视频纹理	表达能力强	算力和数据需求高	用共享 ROI token 作为补充
本项目七头系统	姿态+人体 ROI	多尺度、可解释、轻量	依赖人体检测质量	固定融合并保留成员证据

2.3 创新点与技术贡献

(1) 双尺度因果时序建模。短时分支以 16 帧窗口刻画快速下坠与姿态突变，长时分支使用原生连续 48 帧历史补充完整动作上下文；窗口只访问当前及过去帧，满足在线部署的信息约束。

(2) 共享视觉主干下的双证据融合。骨架分支表达关节几何与运动学，ROI 分支从同一 YOLO 特征图提取人体区域 token，补充骨架无法表达的局部外观和空间信息，同时避免再引入独立大规模 RGB 主干。

(3) 以互补性而非单头峰值选择成员。五折配对审计显示，48 帧单头并非最强单模型，但与六个短时成员的相关系数仅为 0.917-0.937；加入后总体 mAP*、P@R90、P@R95 分别提升 1.335、1.200、1.470 个百分点，说明长时上下文提供了可利用的互补证据。

(4) 无可学习参数的部署融合。最终严格执行七个 raw logits 的算术平均后 sigmoid；不在部署视频上搜索融合权重或阈值。该策略将模型选择与现场推理解耦，使冻结后的输出规则可直接复算。




图 1 模型结构选择的配对验证证据。六头基线与七头候选在相同五折 train-00F 身份上比较。

3 实施方案

3.1 总体架构




图 2 冻结七头部署候选的端到端技术架构。前六个头使用 16 帧短时证据，第七头引入 48 帧长时证据，所有输出在 clip logit 层固定等权融合。

系统由视频解码、姿态与多目标跟踪、短/长时骨架编码、人体 ROI token、七个分类头和固定融合六个层级组成。人体检测与 ROI 特征共享 YOLO11n-pose 视觉主干；时序模块仅处理人物级特征，因此计算复杂度不会随整幅图像的大型视频 backbone 成倍增长。

在时刻 t ，输入为 RGB 帧 $I_t \in \mathbb{R}^{(H \times W \times 3)}$ 。姿态主干输出每位候选人的 17 个 COCO 关键点 $P_t \in \mathbb{R}^{(17 \times 3)}$ 、人体框 $b_t = (x, y, w, h)$ 和检测置信度。跟踪器将相邻帧中 IoU 与中心速度一致的检测关联为同一 track_id，并为短时漏检保留 valid_mask；因此时序网络接收的是“某一入”的连续证据，而非按帧独立的全图预测。

表 6 系统分层架构与输入输出

层级	输入对象	核心变换	输出对象
视觉与姿态	RGB 帧 I_t	YOLO11n-pose 一次前向，检测与特征共享	17 点、人体框、置信度、特征图
轨迹管理	关键点、人体框、中心速度	IoU 匹配、常速度预测、valid_mask	按人分组的 track_id 序列
骨架特征	P_t 、 b_t 及相邻帧差分	坐标归一化、骨骼向量、速度与运动学统计	六类逐人时序特征
视觉证据	共享特征图 + 人体框	对每个人体区域提取 320/640 ROI token	与骨架同步的 ROI 表征
时序与分类	16 帧或 48 帧人物证据	因果卷积、Joint-only Transformer、七个分类头	7 个 raw logits
决策输出	clip 级 7 个 raw	固定均值与 sigmoid	score、候选区间、

层级	输入对象	核心变换	输出对象
	logits		成员输出 JSON

所有跨帧特征以人体框尺度进行归一化：关节坐标采用相对人体中心与宽高的表示，Bone 为相邻关节的有向差，Motion 为相邻时刻的坐标差。这样可降低拍摄距离和人体大小变化对时序量纲的影响；缺失帧不被伪造为真实姿态，而由 valid_mask 显式通知后续模块。

3.2 姿态轨迹与候选事件

每帧姿态检测输出 17 个 COCO 关键点、人体框和置信度。MultiPoseTracker 通过 IoU 匹配与中心速度预测维持 track_id；人数变化和短时漏检通过 valid_mask 与零填充显式表示。候选事件模块对每条轨迹计算人体框中心下移、宽高比变化及横向姿态增益，并在因果回看窗口内形成运动分数。

候选轨迹只用于定位需要进一步分析和展示的片段，并不读取真实人物 ID。烟测片段中，系统选择 track_id=3，候选区间为 0.77-4.77 s，运动峰值位于 2.77 s。

3.3 双尺度时序编码与七头融合

骨架编码器包含 Joint、Bone、Motion、Geometry、Rule 与 Kinematics 六类流。

Joint/Bone 表达姿态拓扑，Motion 表达帧间变化，Geometry/Rule/Kinematics 提供框尺度、相对位置和运动学统计。各流通过轻量因果时序卷积与 Joint-only Transformer 汇聚为 384 维人物 embedding。

短时路径以最近 16 帧为因果窗口，只访问当前及历史帧，并通过因果时序卷积和 Joint-only Transformer 提炼局部姿态变化与关节协同；长时路径沿用同一特征定义、扩展为连续 48 帧，用于区分持续倒地与短暂弯腰、坐下或遮挡。

ROI 分支复用姿态主干的中间特征，并按同一 track_id 的人体框提取 person ROI token。320/640 两种尺度分别服务于低开销区域证据和更丰富的局部外观信息；骨架与 ROI 始终按同一人、同一时间窗对齐。

表 7 七头成员配置与固定融合规则

成员	骨架窗口	ROI 输入	作用
H1 / H3 / H5	16 帧	320 person ROI	短时运动 + 中分辨率人体视觉，多种随机种子
H2 / H4 / H6	16 帧	640 person ROI	短时运动 + 高分辨率人体视觉，多种随机种子
H7	48 帧	320 person ROI	补充连续长时上下文与成员互补性
Fusion	clip 级	7 raw logits	$z = (1/7) \sum z_i$, score=sigmoid(z)

每个成员头先生成一个未归一化 logit z_i ，而不是分别在各头上提前截断为概率。部署阶段的唯一融合规则为 $z = (1/7) \sum_i z_i$ ，score= $\sigma(z)$ 。该顺序保证七个成员具有相同的贡献权重，并使输出可由保存的 member_logits 逐项复算；候选事件只负责标记需要展示或复核的时间段，不参与在现场修改融合权重。

头部训练采用 balanced focal loss，并以动作子类辅助损失塑造表示；各候选分类头固定训练 12 个 head epochs，dense-48 头复用已冻结的共享骨架权重。部署候选包保存训练配置和最终权重，但不包含完整逐 epoch loss 日志，因此本文不生成虚构的训练损失曲线，而使用原始配对审计支撑的结构搜索收敛轨迹。

3.4 训练、验证与模型选择

模型改进经历了规则基线、16 帧因果时序、数据与损失优化、外部预训练、Person-ROI 视觉证据、双分辨率多头和 48 帧长时专家七个阶段。前四阶段用于验证方向与建立表示；从 F1-

320 开始，所有候选固定使用相同 template-grouped 五折、相同 clip 身份、相同聚合和相同 mAP* 实现，因此可以进行逐 clip 配对比较。下表给出关键里程碑，而非只保留最终一次结果。

表 8 从初始基线到七头模型的关键演进

阶段模型	核心变化	mAP* / P90 / P95 (%)	评估协议	结论
Rule-only	姿态运动物理规则	43.827 / 45.872 / 41.782	OF-Syn val, 1,200 clips	初始可运行基线
FallTCN	16 帧因果 TCN	49.987 / 52.770 / 47.204	同一 val 协议	mAP* +6.160 点
端点融合	规则与 TCN 严格对齐	51.562 / 53.476 / 49.647	同一 val 协议	CI 跨 0，保留实验模式
Challenge A	均衡采样 + hard-negative + MIL	57.483 / 60.725 / 54.242	同一 val；代表 seed	三种子通过预注册门
FallVision	外部预训练迁移	68.004 / 69.655 / 66.352	研究阶段 val	建立跨域表示基础
F1-320	共享 Person-ROI 视觉证据	67.650 / 73.717 / 61.584	9,600 train；五折 OOF	同协议主线锚点
双头	320/640 fixed equal-logit	69.205 / 75.179 / 63.231	同一五折 OOF	相对 F1 三项同升
六头	双分辨率 × 三随机种子	70.831 / 77.562 / 64.100	同一五折 OOF	P95 5/5 folds 上升
七头	六头 + 原生 dense-48/320	72.166 / 78.762 / 65.570	同一五折 OOF	最终结构锚点

在可直接配对的五折 OOF 主线上，F1-320 到最终七头的 mAP*、P@R90、P@R95 分别提高 4.516、5.046、3.986 个百分点。七头相对六头的增益为 +1.335/+1.200/+1.470 点；2000 次 template-group paired bootstrap 的 mAP* 增益 95% CI 为 [+0.055,+2.333]，因此 dense-48 作为互补专家晋级。表中早期 1,200-clip validation 与后期 9,600-clip train-only OOF 的样本身份和用途不同，不能把所有数值当作同一测试集上的连续涨幅。全部结构冻结后，唯一一次 1,200-clip 无标签开发验证得到 75.208/77.907/72.509%，只用于部署资格检查；V100 视频输出的 score=0.749772 是单个视频的风险分数，也不等于 mAP* 或比赛准确率。

未晋级路线同样保留在决策链中：单独使用 640 ROI 会改善 P90 但损伤 P95；nested learned weight 的增益区间跨 0 且折间权重摆动；共享 320/640 ROI 头会抹去分辨率异质性；时序注意力、真实失真 replay、置信度 Part-ROI、局部空间统计和语义代价加权均未同时通过 mAP*/P90/P95 保护门。

3.5 推理结果与运行证据




图 3 端到端烟测的运行时证据。左图为 160 帧 CPU 烟测的平均耗时分解，中图为同一片段七个成员 raw logits，右图为完全由姿态运动生成的候选区间。

图 3 记录的是历史 160 帧 CPU 功能烟测：系统完整执行视频解码、姿态、ROI、骨架时序和七头融合，输出 clip score=0.178005；该烟测仅证明链路闭合，不参与模型选择。最新七头部署候选已在 NVIDIA V100 上对 3,960 帧、30 FPS 的完整视频完成端到端实测：运行环境为 PyTorch 2.9.0 + CUDA 12.8，GPU 可用；模型 score=0.749772，总耗时 58.483 s，平均 14.77 ms/frame，约 67.7 FPS。输出候选区间为 45.57 - 49.57 s，峰值位于 47.57 s；该分数与本地约 0.7497 的结果一致。这里报告的是完整视频平均时延，不等同于逐帧 P95；如比赛硬门要求 $P95 \leq 100$ ms，仍需基于逐帧耗时分布单独计算并留存。

表 9 推理结果、运行效率与交付证据

证据对象	结果	来源/口径
OF-Syn validation	mAP* 75.208%; P@R90 77.907%; P@R95 72.509%	一次锁定无标签开发验证; 1,200 clips; 非封存测试
完整视频基准	58.483 s; 14.77 ms/frame (约 67.7 FPS); score=0.749772	NVIDIA V100; PyTorch 2.9.0 + CUDA 12.8; 3,960 帧 / 30 FPS; 端到端平均值
历史 CPU 功能烟测	49.80 ms/frame	160 帧链路核验; 不参与模型选择
模型规模	4.053M; 15.46 MiB FP32	共享 YOLO、骨架与七头
交付完整性	175 个白名单文件; 10.55 MB	MANIFEST.json 逐文件 SHA-256; 已完成 V100 平均时延实测, 逐帧 P95 尚待统计

3.6 工程化、复现与风险控制

部署候选包以 `protocol=edgefall_seven_head_label_blind_runtime_v1` 固定输入输出契约，并在 `MANIFEST.json` 中记录融合规则、模型和源码哈希。合并权重只保存一份共享 `skeleton` 和七个小头，姿态与 ROI 提取复用同一 YOLO 实例；批量推理时复用 `SevenHeadVideoModel`，避免重复加载。结果 JSON 保存 `fps`、`frames`、`proposal`、`member_logits`、`score` 和各阶段耗时。候选包共 175 个白名单文件、10.55 MB，完整测试为 538 passed；V100 完整视频平均时延已经实测为 14.77 ms/frame，但若资格门槛按 P95 判定，仍需补充逐帧分位统计后才能正式关闭该硬门。

表 10 工程部署风险及控制措施

风险	影响	控制措施
遮挡或多人交互	姿态漏检、轨迹切换	保留 <code>valid_mask</code> 、 <code>track_id</code> 与候选区间，部署场景独立验证
摄像机视角变化	人体尺度与运动方向变化	人体归一化、ROI token 和跨场景样本补充
误报带来的处置成本	无效告警	高召回区指标、人工复核和告警审计
隐私与合规	视频涉及个人信息	本地推理、最小留存、访问控制和授权采集
版本漂移	结果不可复现	冻结依赖、权重与 SHA-256 清单

4 结论与潜在应用

本项目从 `rule-only` 43.827% mAP* 的可运行基线起步，先以 16 帧 FallTCN、端点融合和 `hard-negative/MIL` 改善时序排序，再通过 FallVision 预训练和 `Person-ROI` 引入跨域与外观证据。进入统一五折 OOF 主线后，F1-320、双分辨率双头、六头和 `dense-48` 七头依次达到 67.650%、69.205%、70.831% 和 72.166% mAP*；其中 F1-320 到七头在完全相同协议下净提高 4.516 个百分点。该演进说明收益主要来自互补证据与严格筛选，而非无约束地堆叠模型。

最终七头系统共有 4.053M 参数、FP32 参数体积 15.46 MiB：六个 16 帧短时 ROI 头覆盖 320/640 两种分辨率与三组独立随机种子，第七个 `dense-48/320` 专家补充连续长时上下文；七个 raw logits 先算术平均再 sigmoid。无标签候选提议器只读取 RGB、姿态、人体框和轨迹，锁定开发验证为 75.208/77.907/72.509%，但该结果不等同于封存测试或最终比赛成绩。

在业务流程中，模型的定位是“风险发现—人工复核—事件留档”的第一环。摄像头输入经本地推理后，仅将候选时间段、`track_id`、风险分数和成员输出交给值守人员；值守人员结合原始视频、现场情况和既有处置规范确认是否升级通知。由此，算法输出不会被直接等同于医疗诊断或自动处置结论，而是成为缩短人工回看范围的辅助信息。

在养老机构、家庭看护、康复训练和病房辅助值守中，后续产品化仍需针对遮挡、多人交互、小目标、镜头视角、低光和真实跌倒比例建立新的独立数据闭环。当前 V100 完整视频平均时延为 14.77 ms/frame，但尚未保存逐帧分位分布，因此不能把均值写成 P95 硬门已关闭；外部确认集也已被消费，不能继续承担新候选选择。部署时应同时落实最小化采集、本地处理、人工复核、分级访问、告知授权和留存期限，模型输出只作为风险提示而非医疗诊断。

5 参考资料

以下资料包括本项目直接使用的数据集/系统来源，以及七头架构研究报告中实际学习并用于设计、消融或风险判断的论文。列入参考资料不表示相关方法均进入最终候选模型；未晋级路线仍作为负实验设计和停止条件的理论依据。

5.1 数据集与核心方法来源

- [1] Schneider, D., Marinov, Z., Baur, R., Zhong, Z., Düger, R., & Stiefelwagen, R. (2025). OmniFall: A unified staged-to-wild benchmark for human fall detection. arXiv:2505.19889. <https://arxiv.org/abs/2505.19889>
- [2] Kępski, M. (n.d.). UR Fall Detection Dataset. University of Rzeszów. Retrieved September 1, 2026, from <https://www.fenix.ur.edu.pl/~mkepski/ds/uf.html>
- [3] Kępski, M., & Kwolek, B. (2018). Event-driven system for fall detection using body-worn accelerometer and depth sensor. IET Computer Vision, 12(1), 48–58. <https://doi.org/10.1049/iet-cvi.2017.0119>
- [4] Khanam, R., & Hussain, M. (2024). YOLOv11: An overview of the key architectural enhancements. arXiv:2410.17725. <https://arxiv.org/abs/2410.17725>

5.2 时序建模、骨架动作与视觉表征论文

- [5] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature Pyramid Networks for Object Detection. CVPR. https://openaccess.thecvf.com/content_cvpr_2017/html/Lin_Feature_Pyramid_Networks_CVPR_2017_paper.html
- [6] He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask R-CNN. ICCV. https://openaccess.thecvf.com/content_ICCV_2017/html/He_Mask_R-CNN_ICCV_2017_paper.html
- [7] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. ICCV. https://openaccess.thecvf.com/content_ICCV_2017/html/Lin_Focal_Loss_for_ICCV_2017_paper.html
- [8] Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv:1803.01271. <https://arxiv.org/abs/1803.01271>
- [9] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-Excitation Networks. CVPR. <https://arxiv.org/abs/1709.01507>
- [10] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. NeurIPS. <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>

- [11] Farha, Y. A., & Gall, J. (2019). MS-TCN: Multi-Stage Temporal Convolutional Network for Action Segmentation. CVPR.
https://openaccess.thecvf.com/content_CVPR_2019/html/Abu_Farha_MS-TCN_Multi-Stage_Temporal_Convolutional_Network_for_Action_Segmentation_CVPR_2019_paper.html
- [12] Lakshminarayanan, B., Pritzel, A., & Blundell, C. (2017). Simple and Scalable Predictive Uncertainty Estimation Using Deep Ensembles. NeurIPS.
https://proceedings.neurips.cc/paper_files/paper/2017/hash/9ef2ed4b7fd2c810847ffa5fa85bce38-Abstract.html
- [13] Izmailov, P., Podoprikin, D., Garipov, T., Vetrov, D., & Wilson, A. G. (2018). Averaging Weights Leads to Wider Optima and Better Generalization. UAI.
<https://arxiv.org/abs/1803.05407>
- [14] Zhang, Y., Sun, P., Jiang, Y., et al. (2022). ByteTrack: Multi-Object Tracking by Associating Every Detection Box. ECCV.
https://www.ecva.net/papers/eccv_2022/papers_ECCV/html/315_ECCV_2022_paper.php
- [15] Lin, J., Gan, C., & Han, S. (2019). TSM: Temporal Shift Module for Efficient Video Understanding. ICCV.
https://openaccess.thecvf.com/content_ICCV_2019/html/Lin_TSM_Temporal_Shift_Module_for_Efficient_Video_Understanding_ICCV_2019_paper.html
- [16] Gu, A., & Dao, T. (2024). Mamba: Linear-Time Sequence Modeling with Selective State Spaces. COLM. <https://openreview.net/forum?id=tEYskw1VY2>
- [17] Gu, A., Goel, K., & Ré, C. (2022). Efficiently Modeling Long Sequences with Structured State Spaces. ICLR. <https://openreview.net/forum?id=uYLFoz1v1AC>
- [18] Khosla, P., Teterwak, P., Wang, C., et al. (2020). Supervised Contrastive Learning. NeurIPS. <https://proceedings.neurips.cc/paper/2020/hash/d89a66c7c80a29b1bdbab0f2a1a94af8-Abstract.html>
- [19] Cormier, M., Clepe, A., Specker, A., & Beyerer, J. (2024). Enhancing Skeleton-Based Action Recognition in Real-World Scenarios Through Realistic Data Augmentation. WACV Workshops. https://openaccess.thecvf.com/content/WACV2024W/RWS/html/Cormier_Enhancing_Skeleton-Based_Action_Recognition_in_Real-World_Scenarios_Through_Realistic_Data_WACVW_2024_paper.html
- [20] Wolpert, D. H. (1992). Stacked Generalization. Neural Networks, 5(2), 241-259.
<https://www.sciencedirect.com/science/article/pii/S0893608005800231>
- [21] Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. ICML. <https://proceedings.mlr.press/v70/guo17a.html>
- [22] Duan, H., Zhao, Y., Chen, K., Lin, D., & Dai, B. (2022). Revisiting Skeleton-Based Action Recognition (PoseC3D). CVPR.
https://openaccess.thecvf.com/content/CVPR2022/html/Duan_Revisiting_Skeleton-Based_Action_Recognition_CVPR_2022_paper.html
- [23] Yan, S., Xiong, Y., & Lin, D. (2018). Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition. AAAI. <https://arxiv.org/abs/1801.07455>
- [24] Chen, Y., Zhang, Z., Yuan, C., Li, B., Deng, Y., & Hu, W. (2021). Channel-Wise Topology Refinement Graph Convolution for Skeleton-Based Action Recognition. ICCV.
https://openaccess.thecvf.com/content_ICCV2021/html/Chen_Channel-Wise_Topology_Refinement_Graph_Convolution_for_Skeleton-Based_Action_Recognition_ICCV_2021_paper.html
- [25] Chi, H., Ha, M. H., Chi, S., Lee, S. W., Huang, Q., & Ramani, K. (2022). InfoGCN: Representation Learning for Human Skeleton-Based Action Recognition. CVPR.
https://openaccess.thecvf.com/content/CVPR2022/html/Chi_InfoGCN_Representation_Learning_for_Human_Skeleton-Based_Action_Recognition_CVPR_2022_paper.html
- [26] Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent Neural Networks for Multivariate Time Series with Missing Values (GRU-D). Scientific Reports, 8, 6085.
<https://doi.org/10.1038/s41598-018-24271-9>

- [27] Ilse, M., Tomczak, J. M., & Welling, M. (2018). Attention-based Deep Multiple Instance Learning. ICML. <https://proceedings.mlr.press/v80/ilse18a.html>
- [28] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the Knowledge in a Neural Network. arXiv:1503.02531. <https://arxiv.org/abs/1503.02531>

5.3 融合、评价协议与部署研究论文

- [29] Rabinowicz, A., & Rosset, S. (2022). Cross-Validation for Correlated Data. Journal of the American Statistical Association, 117(538), 718–731. <https://arxiv.org/abs/1904.02438>
- [30] Eban, E., Schain, M., Mackey, A., Gordon, A., Rifkin, R., & Elidan, G. (2017). Scalable Learning of Non-Decomposable Objectives. AISTATS. <https://proceedings.mlr.press/v54/eban17a.html>
- [31] Qi, Q., Luo, Y., Xu, Z., Ji, S., & Yang, T. (2021). Stochastic Optimization of Areas Under Precision-Recall Curves with Provable Convergence. NeurIPS. <https://proceedings.neurips.cc/paper/2021/hash/0dd1bc593a91620daecf7723d2235624-Abstract.html>
- [32] Nagrani, A., Yang, S., Arnab, A., Jansen, A., Schmid, C., & Sun, C. (2021). Attention Bottlenecks for Multimodal Fusion. NeurIPS. <https://proceedings.neurips.cc/paper/2021/hash/76ba9f564ebbc35b1014ac498fafadd0-Abstract.html>
- [33] Caruana, R., Niculescu-Mizil, A., Crew, G., & Ksikes, A. (2004). Ensemble Selection from Libraries of Models. ICML. <https://www.cs.cornell.edu/~alexn/papers/shotgun.icml04.revised.rev2.pdf>
- [34] Breiman, L. (1996). Stacked Regressions. Machine Learning, 24, 49–64. <https://statistics.berkeley.edu/sites/default/files/tech-reports/367.pdf>
- [35] van der Laan, M. J., Polley, E. C., & Hubbard, A. E. (2007). Super Learner. Statistical Applications in Genetics and Molecular Biology, 6(1). <https://doi.org/10.2202/1544-6115.1309>
- [36] Do, J., & Kim, M. (2024). SkateFormer: Skeletal-Temporal Transformer for Human Action Recognition. ECCV. https://www.ecva.net/papers/eccv_2024/papers_ECCV/html/5796_ECCV_2024_paper.php
- [37] Rajasegaran, J., Pavlakos, G., Kanazawa, A., Feichtenhofer, C., & Malik, J. (2023). On the Benefits of 3D Pose and Tracking for Human Action Recognition. CVPR, 640–649. https://openaccess.thecvf.com/content/CVPR2023/html/Rajasegaran_On_the_Benefits_of_3D_Pose_and_Tracking_for_Human_CVPR_2023_paper.html
- [38] Dai, R., Das, S., Kahatapitiya, K., Ryoo, M. S., & Brémond, F. (2022). MS-TCT: Multi-Scale Temporal ConvTransformer for Action Detection. CVPR. https://openaccess.thecvf.com/content/CVPR2022/html/Dai_MS-TCT_Multi-Scale_Temporal_ConvTransformer_for_Action_Detection_CVPR_2022_paper.html
- [39] Yao, Y., Vehtari, A., Simpson, D., & Gelman, A. (2018). Using Stacking to Average Bayesian Predictive Distributions. Bayesian Analysis, 13(3), 917–1007. <https://arxiv.org/abs/1704.02030>
- [40] Cotter, A., Jiang, H., Gupta, M., et al. (2019). Training Well-Generalizing Classifiers for Data-Dependent Constraints. ICML. <https://proceedings.mlr.press/v97/cotter19b.html>
- [41] Kondratyuk, D., Yuan, L., Li, Y., et al. (2021). MoViNets: Mobile Video Networks for Efficient Video Recognition. CVPR. https://openaccess.thecvf.com/content/CVPR2021/html/Kondratyuk_MoViNets_Mobile_Video_Netwoks_for_Efficient_Video_Recognition_CVPR_2021_paper.html
- [42] Cawley, G. C., & Talbot, N. L. C. (2010). On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research, 11, 2079–2107. <https://jmlr.org/papers/v11/cawley10a.html>

- [43] Roberts, D. R., Bahn, V., Ciuti, S., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://doi.org/10.1111/ecog.02881>
- [44] Andriluka, M., Iqbal, U., Insafutdinov, E., et al. (2018). PoseTrack: A Benchmark for Human Pose Estimation and Tracking. *CVPR*. https://openaccess.thecvf.com/content_cvpr_2018/html/Andriluka_PoseTrack_A_Benchmark_CVPR_2018_paper.html
- [45] Lea, C., Flynn, M. D., Vidal, R., Reiter, A., & Hager, G. D. (2017). Temporal Convolutional Networks for Action Segmentation and Detection. *CVPR*. https://openaccess.thecvf.com/content_cvpr_2017/html/Lea_Temporal_Convolutional_Networks_CVPR_2017_paper.html